

SISTEMA DE VISIÓN ARTIFICIAL PARA CONDUCCIÓN AUTÓNOMA CON JETSON NANO

- Juan José Prado
Neira
- Javier Rego Bargos





ÍNDICE

Problema a resolver y planteamiento inicial.

Captura de datos.

Etiquetado con MakeSense.

Como se ha preparado el dataset.

Modelo de segmentación.

Entrenamiento.

Exportación y procesado de máscaras.

Lógica de seguimiento del circuito.

Lógica para evitar los obstáculos.

Control del coche en Jetson.

Resultados obtenidos.

Conclusión.



PROBLEMA A RESOLVER Y PLANTEAMIENTO INICIAL

- -Recorrer un circuito de forma autónoma manteniéndose dentro de la zona transitable evitando obstáculos usando imágenes de cámara para que tome decisiones.
- -Para resolver este problema se hará uso de la segmentación semántica para clasificar las zonas de la imagen, planteando inicialmente el uso de deeplab para la tarea de diferenciación de zonas útiles, y usando una Unet pequeña debido a las capacidades limitadas de la Jetson.
- -Las clases de las imágenes se dividirán en “caja” y “circuito”.

CAPTURA DE DATOS

- -Imágenes tomadas a partir de una vuelta del circuito controlada por teclado.
- -Imágenes con la perspectiva real de la ejecución.
- -Alrededor de 57 imagenes para el entrenamiento.





ETIQUETADO CON MAKESENSE

- Se etiquetan manualmente las imágenes en MakeSense.
 - Clase 1: circuito o zona transitable.
 - Clase 2: caja u obstáculo.
 - Se exportan las anotaciones en formato COCO JSON.
 - El notebook convierte esas anotaciones en máscaras binarias.
- 

COMO SE HA PREPARADO EL DATASET

- Cada imagen tiene dos máscaras asociadas:

track_masks para
circuito.

obstacle_masks
para cajas.

- El dataset se divide en entrenamiento y validación.

- En el repositorio:
45 imágenes de
entrenamiento y
12 de validación.

- Las imágenes y máscaras se redimensionan a 256 x 256 píxeles.

MODELO DE SEGMENTACIÓN

-Se utiliza SmallUnet, dándole una imagen RGB como entrada.

-Se obtiene como salida 2 canales, uno para el circuito y otro para el obstáculo.

-La red hace uso de encoder, bottleneck, decoder y conexiones de salto.

-La ventaja de esto es un menor coste que en modelos pasados y es más adecuada para la jetson.



ENTRENAMIENTO

-Se carga el dataset y haciendo uso de PyTorch, Adam y una pérdida de Dice + BCE.

-Se le da más peso a la clase caja porque ocupa menos pixeles.

-Cálculo de métricas de Dice y IoU.

-Se guardan checkpoints para el último modelo y el mejor modelo.

EXPORTACIÓN Y PROCESADO DE LAS MÁSCARAS

-
- Se exporta a ONNX para luego hacer uso de OpenCV DNN y recurrir a ONNX Runtime.
-
- Cada frame se normaliza, pasa por la red y se convierte en máscaras binarias.
-
- Para las máscaras se aplica sigmoide y umbral para obtener las clases.
-
- La máscara del circuito se limpia con operaciones morfológicas.
-
- Se filtran componentes pequeños para reducir ruido.
-
- Se calcula el centro de la zona transitable en una región de interés.

LÓGICA DE SEGUIMIENTO DEL CIRCUITO

- Se compara el centro del circuito con el centro de la imagen.
- Si el circuito aparece desplazado, se genera un error lateral.
- Ese error se transforma en steering.
- Si el coche está centrado, mantiene avance recto.
- Si se pierde el circuito, puede pararse por seguridad.

LÓGICA PARA EVITAR LOS OBSTÁCULOS

- Se analiza la máscara de cajas en la zona frontal.
- Se calcula posición, área y urgencia del obstáculo.
- Caja a la izquierda: giro hacia la derecha.
- Caja a la derecha: giro hacia la izquierda.
- Si el riesgo es alto, se reduce velocidad o se detiene.

CONTROL DEL COCHE EN JETSON

- Recibe comandos auto_drive por socket.

- Aplica steering y throttle con NvidiaRacecar.

- Incluye calibracion de dirección y limites de seguridad.

- Permite control manual con prioridad temporal sobre el automático.

- Tiene watchdog para detener el coche si se pierden comandos.

ARQUITECTURA GENERAL

- circuito_segmentation: dataset, entrenamiento, pruebas y exportación.

- socket_vision: vision en tiempo real, control, comunicación y Jetson.

- El PC se usa para entrenamiento y preparación.

- La Jetson ejecuta inferencia y control del robot.

- El script main.sh sincroniza y lanza el flujo completo.



RESULTADOS OBTENIDOS

Video de la ejecución
del coche.

BIBLIOGRAFÍA

[1] Material docente de Visión Avanzada, "Segmentación con DeepLabv3+,"
Tema 5, 2026.

[2] L.-C. Chen, G. Papandreou, F. Schroff y H. Adam, "Rethinking Atrous
Convolution for Semantic Image Segmentation," arXiv:1706.05587, 2017.

[3] L.-C. Chen, Y. Zhu, G. Papandreou, F. Schroff y H. Adam, "Encoder-
Decoder with Atrous Separable Convolution for Semantic Image Seg-
mentation," en ECCV, 2018.

[4] O. Ronneberger, P. Fischer y T. Brox, "U-Net: Convolutional Networks
for Biomedical Image Segmentation," en MICCAI, 2015.

[5] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep
Learning Library," en NeurIPS, 2019.

CONCLUSIONES