Sistema de visión artificial para conducción autónoma con Jetson Nano

Juan José Prado Neira
Javier Rego Bargos

Mayo 2026

Propuesta de trabajo

1. Extracto

El trabajo consiste en desarrollar un sistema de visión artificial para un coche robot basado en Jetson Nano. El objetivo es que el vehículo pueda seguir un circuito o zona transitable y reaccionar ante cajas u obstáculos detectados en la imagen.

La solución utiliza una red neuronal de segmentación semántica de tipo U-Net. El modelo recibe una imagen RGB y genera dos máscaras: una para el circuito y otra para los obstáculos. A partir de estas máscaras se calcula el error lateral del coche y se generan comandos de control normalizados (*steering* y *throttle*).

El sistema se organiza de forma distribuida: la Jetson captura y envía vídeo, mientras que el portátil ejecuta la inferencia, calcula la acción de control y devuelve las órdenes al vehículo.

2. Introducción

La visión artificial es una herramienta fundamental en robótica móvil, especialmente cuando se necesita interpretar el entorno de forma flexible. En este proyecto se emplea segmentación semántica porque permite obtener información píxel a píxel de la escena, lo que resulta adecuado para seguir una zona de circulación y localizar obstáculos.

El uso de una Jetson Nano permite trabajar con una plataforma real de bajo coste, cercana a aplicaciones de robótica educativa y prototipado. El proyecto combina captura de vídeo, aprendizaje profundo, comunicación por red y control de actuadores.

3. Objetivos

El objetivo general es construir un prototipo funcional de conducción autónoma basado en visión artificial.

Los objetivos concretos son:

- Preparar un dataset propio con imágenes del circuito y máscaras de segmentación.
- Entrenar una red neuronal capaz de segmentar circuito y obstáculos.
- Exportar el modelo a ONNX para su uso en inferencia.
- Integrar el flujo de vídeo Jetson–portátil y el envío de comandos portátil–Jetson.
- Convertir las máscaras de segmentación en órdenes de dirección y velocidad.
- Evaluar el sistema mediante métricas de segmentación y pruebas de conducción.

4. Metodología

Primero se capturan imágenes reales del circuito y se anotan con dos clases: `circuito` y `caja`. A partir de estas anotaciones se generan máscaras binarias para entrenar el modelo.

Después se entrena una U-Net pequeña en PyTorch. La red se diseña con dos salidas para resolver en una sola inferencia tanto el seguimiento del circuito como la detección de obstáculos.

Finalmente, el modelo se exporta a ONNX y se integra en el sistema `socket_vision`. En ejecución, la cámara de la Jetson envía frames al portátil; el portátil segmenta la imagen, calcula el centro del circuito y envía comandos de control al coche.

5. Apartado técnico

5.1. Dataset

Elemento	**Valor**
Imágenes anotadas	57
Anotaciones totales	100
Clases	`circuito`, `caja`
Resolución original	640×360
Imágenes de entrenamiento	45
Imágenes de validación	12
Formato de máscara	Binaria por clase

5.2. Modelo neuronal

Característica	**Valor**
Arquitectura	U-Net ligera
Entrada	$3 \times 256 \times 256$
Salida	$2 \times 256 \times 256$
Canales de salida	Circuito y obstáculo
Canales del encoder	32, 64, 128, 256
Canales del cuello de botella	512
Etapas de bajada/subida	4 / 4
Convoluciones 2D	19
Convoluciones transpuestas	4
BatchNorm + ReLU	18 + 18
Parámetros entrenables	7.763.074

5.3. Entrenamiento e inferencia

6. Plan de trabajo

- **Fase 1:** revisión del problema, definición de requisitos y preparación del entorno.
- **Fase 2:** captura, anotación y organización del dataset.
- **Fase 3:** entrenamiento, validación y exportación del modelo.
- **Fase 4:** integración del modelo en el flujo Jetson–portátil.

Elemento	Valor
Framework de entrenamiento	PyTorch 2.11
Optimizador	Adam
Learning rate	10^{-3}
Batch size	8
Función de pérdida	BCEWithLogits + Dice Loss
Métricas	Dice e IoU
Checkpoint seleccionado	`best_model.pth`
Mejor época	78
Dice de validación del mejor modelo	0.9519
Pérdida de validación del mejor modelo	0.1175
Formato de exportación	ONNX
Resolución de captura	512×288
Frecuencia objetivo	12 FPS
Comandos de salida	*steering*, *throttle*

- **Fase 5:** ajuste del control autónomo y pruebas con obstáculos.
- **Fase 6:** evaluación final, análisis de resultados y redacción de la memoria.

7. Evaluación prevista

La evaluación del sistema completo incluirá FPS, latencia, estabilidad del seguimiento del circuito, respuesta ante obstáculos y necesidad de intervención manual.